

Trabalho Prático - Banco de Dados Geográficos e Ciência de Dados Geoespaciais

Dados Eleitorais Espacializados no Estado do Rio de Janeiro

Ana Luisa Messias Ferreira Mendes¹, Carla Beatriz Ferreira¹, Clara Garcia Tavares¹,
Filipe Mauro da Terra Caldeira¹

¹Departamento de Ciência da Computação - Instituto de Ciências Exatas
Universidade Federal de Minas Gerais (UFMG)
CEP 31270-901 – Belo Horizonte, MG, Brazil

{analuisa.mendes, carlaferreira, claratavares,
filipecaldeira}@dcc.ufmg.br

Abstract. *This document describes the process and results obtained from the execution of the practical work for the course Geographic Databases and Geospatial Data Science at the Federal University of Minas Gerais (UFMG) in 2025/2. This documentation aims to describe the datasets, tools, and decisions made for the construction of the spatial database regarding the 2022 State Deputy elections in Rio de Janeiro. Combining information on voting, geographic meshes, census data, and public security data, we present the transformations performed and the limitations observed. Furthermore, we present the results obtained from geospatial SQL queries and the visualizations generated, comparing different elected candidates.*

Resumo. *Este documento descreve o processo e resultados obtidos para a execução do trabalho prático da disciplina Banco de Dados Geográficos e Ciência de Dados Geoespaciais na Universidade Federal de Minas Gerais (UFMG) em 2025/2. A presente documentação visa descrever os conjuntos de dados, ferramentas e decisões tomadas para construção do Banco de Dados espacial referente a eleições de Deputado Estadual no Rio de Janeiro em 2022. Juntando informações de votação, malhas geográficas, dados censitários e de segurança pública, apresentamos as transformações realizadas e limitações observadas. Além disso, apresentamos resultados obtidos com buscas SQL geoespaciais e visualizações obtidas, comparando diferentes candidatos eleitos.*

1. Introdução

De acordo com (Casanova et al. 2005), para a produção de representações computacionais do espaço geográfico precisamos conectar as percepções do mundo real com modelos lógicos, utilizando a tecnologia como elemento do processo. Seguindo a ideia de que coisas próximas estão mais relacionadas do que coisas distantes (Tobler 1970), pretendemos analisar diferentes informações a respeito da mesma área geográfica: o estado do Rio de Janeiro.

Este relatório descreve todo o processo e resultados do Trabalho Prático sobre Dados Eleitorais Espacializados, focada na construção de um Banco de Dados Geográfico

(BDG). O objetivo é analisar os resultados eleitorais de 2022 para o cargo de Deputado Estadual, utilizando como unidade de referência o estado do Rio de Janeiro.

O trabalho exigiu a integração de dados de múltiplas fontes: os dados eleitorais como fonte primária, dados geográficos para espacialização, dados censitários como informação socioeconômica e dados de um tema complementar. Além disso, foi necessário a utilização de ferramentas e estratégias de análise e visualização de dados espaciais, visando comparação entre diferentes candidatos e correlações com informações disponíveis. Todo o processo foi baseado no desenvolvimento proposto na motivação do trabalho e apresentado na Figura 1

Esta documentação está dividida nas seções: Aquisição de Dados, Engenharia de Dados e Análise e Visualização dos Dados, seguidas de uma breve conclusão sobre o processo.




Figura 1. Diagrama do processo. Adaptado de (Davis Jr 2025)

2. Aquisição de Dados

A primeira etapa do projeto consistiu na identificação, coleta e avaliação das fontes de dados necessárias para a composição do banco de dados. Conforme proposto pelo enunciado, foram utilizadas quatro esferas de recursos como informações a serem agregadas a analisadas, descritas a seguir.

2.1. Fonte de dados eleitorais

A fonte primária, seguindo a premissa proposta, é o Portal de Dados Abertos do Tribunal Superior Eleitoral (TSE). Foram adquiridos os resultados da votação das Eleições de 2022¹, especificamente o arquivo CSV (*Comma-Separated Values* - Valores Separados por Vírgulas) referente à votação nominal por município e zona para o Rio de Janeiro. O registro foi obtido dentro da divisão de todos os resultados do país, visto que o link para votação por seção eleitoral especificamente do estado do Rio de Janeiro² está incorreto no site, fornecendo informações apenas para presidente e não para todos os cargos votados. Mais detalhes sobre limitações e tratamento realizado estão descritos nas seções seguintes.

2.2. Fontes de Dados Geográficos

Para permitir a espacialização e, principalmente, a agregação dos resultados eleitorais, foram necessários dados geográficos. As fontes utilizadas foram as diferentes agregações

¹<https://dadosabertos.tse.jus.br/dataset/resultados-2022>

²https://cdn.tse.jus.br/estatistica/sead/odsele/votacao_secao/votacao_secao_2022_RJ.zip

de "Malhas territoriais", obtidas no portal de dados do Instituto Brasileiro de Geografia e Estatística (IBGE)³.

Estas malhas vetoriais serão a base para as agregações espaciais nos três níveis exigidos pelo enunciado: município, região geográfica imediata e região geográfica intermediária. A qualidade da malha foi verificada, confirmando a compatibilidade dos códigos de municípios com os fornecidos pelo TSE e IBGE, bem como a adequação do sistema de referência de coordenadas (CRS).

2.3. Fonte de Dados Censitários

Para a análise de correlação socioeconômica, o grupo buscou dados ao nível municipal e decidiu por utilizar informações de alfabetização, apresentados no Censo Demográfico 2022 disponibilizado pelo IBGE⁴, ao nível municipal e com filtros por diferentes categorizações de idade e renda familiar.

2.4. Fonte de Dados Complementar

Como fonte de dados complementar, o grupo optou por estatísticas de segurança disponibilizados pelo portal de Dados Abertos GOV⁵, contendo a série histórica mensal por município desde 2014. Essas informações permitirão análises sobre a relação entre votação e segurança pública no estado do Rio de Janeiro, agregado por municípios.

3. Engenharia de Dados

Com as informações brutas obtidas a partir dos arquivos baixados dos portais de disponibilização de dados abertos, foi iniciada a etapa de construção do Banco de Dados Geográfico, engenharia de dados a partir de transformações e seleção de dados e, por fim, análise exploratória inicial. A organização adotada, estratégias adotadas e métricas estatísticas obtidas estão detalhadas nas seções a seguir.

3.1. Organização e Agregação

A principal tarefa de engenharia de dados foi a agregação e organização dos dados necessários. Para refinamento dos arquivos utilizamos bibliotecas Python já conhecidas (como Pandas e OS) para manipulação dos dados, criando novos registros, agrupando informações relevantes e eliminando colunas e linhas desnecessárias para o nosso cenário. Todo o processo foi feito a partir de um repositório público no github⁶ compartilhado entre os integrantes.

Os dados de votação do TSE, originalmente no nível de seção eleitoral, foram agregados para o nível municipal, utilizando os códigos oficiais do município. Para os conjuntos de alfabetização, segurança e votação, foram definidas colunas de interesse a serem mantidas e linhas a serem utilizadas, visto, por exemplo, que nem todos os anos seriam utilizados para métricas de segurança e nem todos os cargos votados seriam analisados para o contexto de deputado estadual. Um resumo das colunas e linhas mantidas está apresentado nas Tabelas 1 e 2.

³<https://www.ibge.gov.br/geociencias/organizacao-do-territorio/malhas-territoriais/15774-malhas.html>

⁴<https://www.ibge.gov.br/estatisticas/sociais/saude/22827-censo-demografico-2022.html?=&t=downloads>

⁵<https://dados.gov.br/dados/conjuntos-dados/isp-estatisticas-de-seguranca-publica>

⁶https://github.com/carlabferreira/RJ_election_analysis

Conjunto de dados	Colunas mantidas	Colunas descartadas
	CD_ELEICAO, DS_ELEICAO, NM_CANDIDATO, NR_PARTIDO, NM_PARTIDO, NM_TIPO_DESTINACAO_VOTOS, QT_VOTOS_NOMINAIS_VALIDOS, DS_SIT_TOT_TURNO	DT_GERACAO, HH_GERACAO, ANO_ELEICAO, CD_TIPO_ELEICAO, NM_TIPO_ELEICAO, NR_TURNO, DT_ELEICAO, TP_ABRANGENCIA, SG_UF, SG_UF, NM_UE, NR_ZONA, CD_CARGO, DS_CARGO, SQ_CANDIDATO, NM_URNA_CANDIDATO, NM_SOCIAL_CANDIDATO, CD_SITUACAO_CANDIDATURA, DS_SITUACAO_CANDIDATURA, CD_DETALHE_SITUACAO_CAND, DS_DETALHE_SITUACAO_CAND, CD_SITUACAO_JULGAMENTO, DS_SITUACAO_JULGAMENTO, CD_SITUACAO_CASSACAO, DS_SITUACAO_CASSACAO, CD_SITUACAO_DCONST_DIPLOMA, DS_SITUACAO_DCONST_DIPLOMA, TP_AGREMIACAO, NR_FEDERACAO, NM_FEDERACAO, SG_FEDERACAO, DS_COMPOSICAO_FEDERACAO, SQ_COLIGACAO, NM_COLIGACAO, DS_COMPOSICAO_COLIGACAO, ST_VOTO_EM_TRANSITO, QT_VOTOS_NOMINAIS, CD_SIT_TOT_TURNO
Alfabetização	CD_MUN, NM_MUN, V007[48-60]	V00[644-747], V0[0761-1005]
Estatísticas de segurança	fmun_cod, fmun, ano, total_roubos, total_furtos, registro_ocorrencias	mes, mes_ano, regioao, hom_doloso, lesao_corp_morte, latrocínio, cvli, hom_por_interv_policia, letalidade_violenta, tentat_hom, lesao_corp_dolosa, estupro, hom_culposo, lesao_corp_culposa, roubo_transeunte, roubo_celular, roubo_em_coletivo, roubo_rua, roubo_veiculo, roubo_carga, roubo_comercio, roubo_residencia, roubo_banco, roubo_cx_eletronico, roubo_conducao_saque, roubo_apos_saque, roubo_bicicleta, outros_roubos, furto_veiculos, furto_transeunte, furto_coletivo, furto_celular, furto_bicicleta, outros_furtos, sequestro, extorsao, sequestro_relampago, estelionato, apreensao_drogas, posse_drogas, trafico_drogas, apreensao_drogas_sem_autor, recuperacao_veiculos, apf, aaapai, cmp, cmba, ameaca, pessoas_desaparecidas, encontro_cadaver, encontro_ossada, pol_militares_mortos_serv, pol_civis_mortos_serv, fase

Tabela 1. Colunas mantidas pós filtragem

Conjunto de dados	Variações de Linhas mantidas	Linhas descartadas
Dados Eleitorais	Linhas em que o código de cargo era deputado estadual (CD_CARGO == 7)	Todas as linhas em que o cargo não era deputado estadual
Alfabetização	Linhas onde a coluna da Unidade Federativa (UF) era correspondente ao Rio de Janeiro (CD_MUNICIPIO unido a uf and cod_ibge, uf = "RJ")	Linhas referentes a informações de municípios não pertencentes ao Rio de Janeiro
Estatísticas de segurança	Linhas em que o ano de referência era 2021	Linhas em que o ano de referência não era 2021

Tabela 2. Linhas mantidas pós filtragem

3.1.1. Padronização de código de municípios

A padronização ou falta de normalização de nomes geográficos e a variedade de opções de escrita de uma mesma palavra a variar sua formatação são um importante problema em questões de referenciamento de cidades e pontos no espaço geográfico (Moreira and Fernandes 2018).

Como os nomes dos municípios estavam apresentados de maneiras diferentes e passíveis de erro devido à acentuação e padronização, optamos por utilizar o código IBGE⁷ de cada município para tratamento e identificação individual. Esse código composto por 4 ou 5 dígitos foi utilizado para correta indicação e comparação de informações de diferentes bases.

3.2. Modelagem

Proposto por (Casanova et al. 2005), o modelo OMT-G se baseia no conceito de classes, relacionamentos e restrições de integridade espaciais para modelar a geometria e a topologia dos dados. Utilizando o site aqui.io⁸, foi elaborado um esquema detalhando as classes de objetos (geográficos e convencionais) e suas inter-relações. O esquema final está apresentado na Figura 2.

⁷https://cdn.tse.jus.br/estatistica/sead/odsele/municipio_tse_ibge/municipio_tse_ibge.zip

⁸<http://aqui.io/omtg-designer/>




Figura 2. Esquema OMT-G.

3.3. Importação e Transformações de Dados

Todos os conjuntos de dados obtidos anteriormente, arquivos CSV e malhas vetoriais, foram importados para um banco de dados geográfico PostgreSQL com extensão PostGIS. Durante este processo, foram necessárias transformações, como a padronização dos tipos de dados citadas nas seções anteriores e a união (*join*) das tabelas eleitorais e censitárias com as geometrias dos municípios.

Para correta comunicação e alinhamento de como e quais ferramentas utilizar, foi elaborado um guia básico no mesmo repositório público supracitado ⁹, tendo como base os tutoriais e guias de instalação das ferramentas PostgreSQL, PgAdmin e PostGis ¹⁰ ¹¹, QGIS ¹² e utilização das bibliotecas Python como GeoPandas¹³, além de orientações fornecidas em sala e em (Davis Jr 2025).

3.4. Análise Exploratória

Uma análise exploratória utilizando Python foi realizada para identificar características, limitações e a qualidade geral dos dados integrados. Os resultados iniciais estão apresentadas nas Tabelas 3, 4 e 5 e suas informações e códigos utilizados para obtenção estão disponíveis no repositório disponibilizado.

Como foi verificado que o município do Rio de Janeiro foi o maior tanto em número de alfabetizados como em quantidade de furtos, houve a preocupação dos dados

⁹https://github.com/carlabferreira/RJ_election_analysis

¹⁰<https://postgis.net/workshops/postgis-intro/installation.html>

¹¹https://www.pgadmin.org/docs/pgadmin4/latest/import_export_data.html

¹²<https://qgis.org/resources/installation-guide/>

¹³<https://geopandas.org/en/stable/>

Conjunto de dados	Nº municípios	Nº de células em branco	Nº de duplicatas
Dados Eleitorais	92	0	0
Alfabetização	92	0	0
Estatísticas de segurança	92	0	0

Tabela 3. Dados de verificação obtidos com análise exploratória inicial

Informação	Valor
Média de pessoas alfabetizadas de 15 a 29 anos	11836.78
Média de pessoas alfabetizadas de 30 a 44 anos	13040.00
Média de pessoas alfabetizadas de 45 a 59 anos	11086.16
Média de pessoas alfabetizadas de 60 a 79 anos	8707.87
Média de pessoas alfabetizadas de 80 anos ou mais	4003.92
Município com maior número de alfabetizados	Rio de Janeiro (5029309 pessoas)
Município com menor número de alfabetizados	Macuco (4106 pessoas)

Tabela 4. Dados estatísticos de alfabetização no RJ obtidos com análise exploratória inicial

Informação	Valor
Média de furtos por município	1245.89
Média de roubos por município	1256.99
Média razão furto/roubo no estado	8.60
Correlação entre furtos e roubos (2021)	0.99
Município com mais furtos	Rio de Janeiro (67913 casos)
Município com menos furtos	São José de Ubá (6 casos)

Tabela 5. Dados estatísticos de segurança em 2021 no RJ obtidos com análise exploratória inicial

Nº Candidado	Nome	Votos Nominais Válidos
44123	Márcio Correia de Oliveira	181274
22022	Douglas Ruas dos Santos	175977
50007	Renata da Silva Souza	174132
15016	Rosenverg Reis de Oliveira	131308
22122	Sérgio Luiz Costa Azevedo Filho	123739
22222	Guilherme Jandre Delaroli	114155
22200	Thiago Gagliasso Onofre Ferreira	102038
22789	Rodrigo da Silva Bacellar	97822
13021	Elika Takimoto	95263
22822	Giselle Louise Monteiro de Oliveira	95028

Tabela 6. Candidatos a Governador Estadual mais votados no RJ

estarem, na verdade, refletindo apenas informações sobre população, problema comum em visualizações espaciais (Davis Jr 2025). Com isso em foco, foi observado também a informação de população total por município, para comparação nas análises, realizando a aproximação de população por total de votos, proposta já realizada por (Davis Jr 2025).

4. Análise e Visualização dos Dados

A análise espacial é um conjunto de métodos cujos resultados mudam se a localização dos objetos em análise muda (Longley, 2011 apud Davis Jr, 2025). Com isso em foco, analisamos os candidatos mais votados, como resultado apresentado na Tabela 6, e diversas investigações de autocorrelação espacial e correlação com dados auxiliares, apresentando resultados e visualizações nas seções a seguir.

4.1. Autocorrelação Espacial

Para esta análise, foram selecionados dois candidatos com perfis de votação geograficamente distintos, mas com desempenho eleitoral total extremamente semelhante:

- **Candidato A (Votação Regionalizada):** Douglas Ruas dos Santos (PL) – 175.977 votos.
- **Candidata B (Votação Ampla):** Renata da Silva Souza (PSOL) – 174.132 votos.

A escolha é estratégica: a proximidade numérica dos votos totais permite isolar a magnitude da popularidade e focar exclusivamente na geografia do voto (concentração *versus* dispersão). O objetivo é identificar, através de indicadores espaciais, a existência de *clusters* de votação ou a predominância de dispersão territorial.

4.1.1. Metodologia e Processamento

Para identificar padrões geográficos, utilizou-se a metodologia dos Indicadores Locais de Associação Espacial (LISA). Diferente do Índice de Moran Global, que resume a autocorrelação em um único valor, o LISA decompõe o indicador para cada município, permitindo detectar *clusters* locais (agrupamentos) e *outliers* (Anselin 2024).

Os dados foram processados no PostgreSQL para calcular o percentual de votos de cada candidato em relação aos votos válidos locais. No QGIS, aplicou-se a ferramenta

nativa de união espacial com critério de contiguidade *Queen* (Rainha) para calcular o Lag Espacial (média da vizinhança). A classificação dos municípios nos quadrantes de Moran baseou-se na comparação entre o valor local (x_i), a média dos vizinhos (w_i) e a média global do estado (μ):

- **High-High (HH):** Municípios com alta votação cercados por vizinhos de alta votação (indicativo de *cluster* positivo).
- **Low-Low (LL):** Municípios com baixa votação cercados por vizinhos de baixa votação (áreas frias).
- **High-Low (HL) e Low-High (LH):** Situações de transição ou *outliers* espaciais.

4.1.2. Resultados e Discussão

Candidato A: Douglas Ruas (Perfil Regionalizado)

A análise confirma um padrão de Autocorrelação Espacial Positiva Extrema. O candidato apresenta uma concentração massiva de votos em um único município, São Gonçalo, onde obteve 149.576 votos (85,00% de seu eleitorado). O caráter de *cluster* geográfico (High-High) é confirmado pela vizinhança imediata, que também concentra a maior parte dos votos restantes:

- **Niterói:** 5,00% (8.796 votos);
- **Itaboraí:** 2,16% (3.805 votos);
- **Maricá:** 1,47% (2.588 votos).

Somados, esses quatro municípios contíguos da Região Metropolitana concentram 93,63% da votação total do candidato. Isso gera no mapa LISA (Figura 3) uma mancha verde sólida de *High-High*, caracterizando o fenômeno de “curral eleitoral”. Em contrapartida, o mapa apresenta vastas áreas em *Low-Low*, correspondendo a dezenas de municípios do interior onde o candidato obteve votação residual ou nula.




Figura 3. Mapa LISA - Clusters de Votação de Douglas Ruas (Vermelho: Alto-Alto).

Para corroborar a identificação dos *clusters*, o mapa de desempenho percentual local (Figura 4) exhibe a penetração eleitoral do candidato normalizada pelo tamanho

do eleitorado. Este indicador representa a porcentagem de votos obtidos pelo candidato em relação ao total de votos válidos contabilizados em cada município ($Pct = v_i / V_{total_cidade} \times 100$).

A visualização confirma a disparidade extrema. A classe de maior intensidade isola exclusivamente o município de São Gonçalo, onde o candidato conquistou 35,46% de todos os votos válidos da cidade, um desempenho hegemônico incomum em eleições proporcionais.

O contraste com o restante do território é abrupto:

- Na vizinhança imediata (Niterói e Itaboraí), sua penetração cai drasticamente para a casa dos **3,2%**.
- Em municípios da Região dos Lagos e Baixada, como Maricá e Rio Bonito, a votação gira em torno de **2,6% a 2,9%**.
- Na vasta maioria do estado (mais de 80 municípios), sua representatividade torna-se residual, com percentuais inferiores a **0,5%** (ex: Nova Iguaçu 0,13% e Duque de Caxias 0,08%).

É importante salientar que o candidato obteve zero votos em 6 municípios (como Varre-Sai, Duas Barras e Engenheiro Paulo de Frontin), reforçando que o *cluster High-High* não é um artefato estatístico, mas reflexo de uma votação geograficamente restrita e dependente de uma única base municipal.




Figura 4. Desempenho Percentual Local - Candidato Douglas Ruas.

Candidata B: Renata Souza (Perfil Amplo)

Em contraste, a análise da candidata Renata Souza revela um padrão espacial distinto, caracterizado pela polarização na Metrópole e dispersão secundária nos polos regionais.

Embora a candidata também apresente uma base forte em um único município, o Rio de Janeiro (Capital), onde obteve 74,49% de sua votação total (129.717 votos), a distribuição do restante dos votos não segue a lógica de contiguidade imediata (vizinhos de muro) do candidato anterior. Os votos subsequentes estão pulverizados entre grandes centros urbanos não necessariamente vizinhos e cidades universitárias:

- **Niterói:** 3,38% (5.894 votos);
- **Nova Iguaçu:** 2,11% (3.671 votos);
- **Duque de Caxias:** 2,01% (3.505 votos);
- **Macaé:** 1,48% (2.580 votos) – Polo do Norte Fluminense.

Diferente de Douglas, que concentrou 93% em apenas 4 cidades vizinhas, Renata Souza apresenta uma "cauda longa" de votação. Ela precisaria somar os 13 maiores municípios (incluindo cidades distantes como Cabo Frio, Volta Redonda e Petrópolis) para atingir a mesma marca acumulada de 90% dos votos.

O mapa LISA (Figura 5) reflete essa fragmentação. Embora exista um *cluster High-High* na Capital, observa-se a presença de áreas de transição (*Low-High*) e uma dispersão de votos que impede a formação de um bloco único e maciço em todo o estado.




Figura 5. Mapa LISA - Clusters de Votação de Renata Souza.

Análise da Distribuição Percentual de Votos (Renata Souza)

Para complementar a análise, o mapa de desempenho percentual local (Figura 6) confirma o caráter ideológico/urbano da votação.

A visualização destaca a Capital como polo primário, com uma penetração de 4,39% dos votos válidos da cidade (o maior percentual proporcional dela). Diferentemente do isolamento observado no candidato anterior, nota-se uma presença capilarizada em polos regionais importantes como Macaé (2,43%), Três Rios (2,15%) e Rio das Ostras (1,66%), onde a candidata mantém percentuais de voto visíveis, não caindo a zero absoluto em nenhum município. Isso sugere que sua votação segue a densidade demográfica, transpondo as barreiras da vizinhança geográfica.




Figura 6. Desempenho Percentual Local - Candidata Renata Souza.

4.2. Autocorrelação espacial em nível agregado

4.2.1. Objetivos e Metodologia

Para essa análise foram utilizadas as agregações espaciais de Regiões Geográficas Imediatas (14 regiões) e Regiões Geográficas Intermediárias (5 regiões), exemplificado na Figura 7 com autocorrelação de quantidade de pessoas alfabetizadas, visando refazer as análises supracitadas e verificar preservação ou alteração do comportamento constatado na etapa anterior. O procedimento buscou verificar a robustez dos índices de I de Moran Global e identificar possíveis efeitos de escala sobre os padrões de distribuição espacial.




Figura 7. Autocorrelação de alfabetização em agregações de regiões imediatas e intermediárias

4.2.2. Resultados

Candidato A: Douglas Ruas (Perfil Regionalizado)

A partir das diferentes agregações apresentadas na Figura 8, podemos observar que o comportamento de um perfil regionalizado, com autocorrelação espacial positiva extrema, se manteve para o candidato de número 22022.

Douglas Ruas - Regiões Imediatas

- **Moran Global (I)** = 0.1090
- **P-Valor** = 0.1180

Douglas Ruas - Regiões Intermediárias

- **Moran Global (I)** = -0.3228
- **P-Valor** = 0.2880




Figura 8. Candidato Douglas - Regiões Imediatas e Intermediárias

Candidata B: Renata Souza (Perfil Amplo)

De forma semelhante, a partir das diferentes agregações apresentadas na Figura 9, podemos observar que o comportamento de um perfil amplo, com dispersão de votos por todo o estado, se manteve para a candidata de número 50007.

Renata Souza - Regiões Imediatas

- **Moran Global (I)** = 0.1090
- **P-Valor** = 0.1340

Renata Souza - Regiões Intermediárias

- **Moran Global (I)** = -0.3228
- **P-Valor** = 0.2710




Figura 9. Candidata Renata - Regiões Imediatas e Intermediárias

4.3. Correlação com dados socioeconômicos e de segurança

4.3.1. Objetivos e Metodologia

Esta seção tem como objetivo verificar se existe correlação entre a votação dos candidatos escolhidos e características socioeconômicas dos municípios, verificando se essa correlação é espacializada. Para isso, consideramos os dois candidatos anteriores, Renata Souza e Douglas Ruas, e também o candidato mais votado, Márcio Oliveira, realizando a comparação entre o percentual de votos dos municípios para cada um deles com o percentual de pessoas alfabetizadas em cada localidade.

Além disso, utilizamos também os dados de segurança para comparação. A metodologia consistiu na integração de bases de dados heterogêneas (TSE, IBGE e ISP-RJ) via scripts em Python, permitindo o cruzamento de geometrias municipais com dados censitários e eleitorais. Para a validação estatística, foram aplicados dois métodos complementares: a Correlação de Pearson, para aferir a associação linear global, e o Índice de Moran Bivariado, para identificar a dependência espacial entre a votação em um município e as características socioeconômicas de sua vizinhança.

4.3.2. Resultados

Percentuais de Alfabetização

A quantidade total de pessoas alfabetizadas possui maior concentração próximo à capital e algumas regiões isoladas como Volta Redonda, Cabo Frio e Campo dos Goytacazes. Isso faz com que o mapa tenha muita diferença dentre distribuições, desde cidades com apenas 1.000 habitantes e a capital que possui mais de 1.000.000 de pessoas alfabetizadas, mostrando a influência da demografia e urbanização na quantidade de alfabetizadas, apresentado na Figura 10. Dessa forma, para comparar de forma mais acertiva, consideramos o percentual de pessoas alfabetizadas pelo total da população do município, com esta última sendo adaptada a partir do total de votos do município, conforme sugerido em (Davis Jr 2025). O resultado percentual está apresentado na Figura 11.




Figura 10. Total de alfabetizados por município




Figura 11. Percentual de alfabetização por município

Índice de Furtos e Roubos

Também foram extraídos os dados de Furtos e Roubos por município para que fosse feita uma correlação com os dados de votação. As figuras 12 e 13 apresentam a quantidade total das ocorrências nos municípios. De forma semelhante, os valores também possuem maior concentração próximo à capital e algumas regiões isoladas como Campo dos Goytacazes e Macaé. Isso pode estar diretamente relacionado com a quantidade de habitantes, assim como os dados de alfabetização. Dessa forma, na Figura 14 é apresentado os valores percentuais, também adaptados a partir do total de votos.




Figura 12. Quantidade de furtos registrada por município




Figura 13. Quantidade de roubos registrada por município




Figura 14. Percentual de roubos+furtos registrada por município

Candidato A: Douglas Ruas

O candidato Douglas Ruas (22022) situa-se em um patamar intermediário — com correlação moderada apenas para criminalidade ($r = 0.30$). A análise demonstra que o comportamento do eleitor não é uniforme em todo o território. 15 A significância estatística encontrada no Moran Bivariado para os casos de maior correlação global reforça a hipótese de que o voto possui dependência espacial: o desempenho de um candidato não é um evento isolado, mas influenciado pelo contexto socioeconômico regional em que o município e seus vizinhos estão inseridos.




Figura 15. Correlação candidato Douglas Ruas

Candidata B: Renata Souza

A candidata Renata Souza (50007) apresentou as correlações mais robustas, exibindo forte associação positiva tanto com a taxa de alfabetização ($r = 0.46$; $p < 0.01$) quanto com a criminalidade ($r = 0.56$; $p < 0.01$) 16. Além disso, os índices de Moran Bivariado positivos (0.169 e 0.306) confirmam que sua votação é espacialmente concentrada em regiões (e vizinhanças) com maiores índices nessas variáveis, sugerindo um voto urbano ou metropolitano consolidado.




Figura 16. Correlação candidata Renata Souza

Candidato C: Márcio Oliveira

O candidato Marcio Correia (44123) não apresentou correlação linear global significativa com nenhuma das variáveis, embora o Índice de Moran tenha detectado uma leve autocorrelação espacial com a criminalidade ($p = 0.001$), indicando um padrão de voto que não segue linearmente os indicadores socioeconômicos testados 17. Com isso, é possível concluir que a dimensão espacial e socioeconômica desempenha papéis variados dependendo do candidato analisado.




Figura 17. Correlação candidato Márcio Oliveira

4.4. Autocorrelação espacial por partido

4.4.1. Objetivos e Metodologia

Esta seção pretende comparar um grupo pequeno de partidos mais representativos, neste caso os quatro partidos mais votados, para verificar diferenças e semelhanças entre suas distribuições de votos pelo estado e autocorrelações espaciais. Os partidos mais votados, considerando o total de votos nominais válidos, são Partido Liberal (PL), União, Partido Social Democrático (PSD) e Partido dos Trabalhadores (PT).

A metodologia empregada utilizou a linguagem Python e bibliotecas de econometria espacial (esda e libpysal) para calcular a proporção de votos de cada legenda por município. Para mensurar o grau de dependência geográfica do eleitorado, foi aplicado o índice Global de Moran (Moran's I) sobre uma matriz de pesos de contiguidade, permitindo identificar se o desempenho eleitoral dos partidos segue um padrão agrupado (clustered) ou disperso aleatoriamente no território.

4.4.2. Resultados

Os resultados evidenciaram uma discrepância marcante nas estratégias e capilaridade das legendas. O Partido Liberal (PL) 18 destacou-se com o maior índice de autocorrelação espacial ($I = 0.420$), configurando um padrão de "Agrupamento". Estatisticamente, isso indica que municípios com altavotação no PL tendem a ser vizinhos de outros municípios com desempenho similar, sugerindo a existência de bases eleitorais consolidadas ou re-dutos regionais fortes.

Em contraste, os demais partidos apresentaram índices significativamente menores: PT ($I = 0.215$), UNIÃO ($I = 0.162$) e PSD ($I = 0.119$). Embora o PT 19 ainda apresente uma leve tendência de agrupamento, os valores baixos para este grupo indicam uma distribuição mais pulverizada, característica do chamado "voto de opinião" ou de máquinas partidárias que não dependem estritamente da contiguidade geográfica para obter votos.




Figura 18. Distribuição de votos entre partidos - 1




Figura 19. Distribuição de votos entre partidos - 2

4.5. Análise Extra: Geografia Partidária e Competitividade Eleitoral

4.5.1. Objetivos e Metodologia

Esta etapa estende a investigação para além dos candidatos individuais, analisando a dinâmica político-partidária do estado sob duas perspectivas complementares:

1. **Dominância Partidária:** Identificação de qual partido obteve a maior soma de votos nominais em cada município, revelando a distribuição dos eixos políticos no estado.
2. **Competitividade (Índice HHI):** Mensuração do grau de concentração de votos em cada localidade através do Índice Herfindahl-Hirschman (HHI), uma métrica que varia de 0 (alta fragmentação) a 1 (monopólio de votos).

A metodologia consistiu no processamento de dados no PostgreSQL para agregar votos por partido e calcular o HHI municipal. Para a visualização partidária, os vencedores foram agrupadas em três eixos ideológicos, Direita, Esquerda e Centro. Esta classificação baseou-se no alinhamento político tradicional dos partidos no cenário nacional durante o pleito de 2022, conforme abaixo:¹⁴:

¹⁴Classificação de espectro político baseada na autodefinição partidária e análise de coligações,

- **Eixo Direita (Azul):** PL, PP, PSC, DC, AGIR.
- **Eixo Centro (Verde):** MDB, PSD, PODE, UNIÃO.
- **Eixo Esquerda (Vermelho):** PT, PSOL, PDT, SOLIDARIEDADE, PROS.

4.5.2. Resultados

A análise espacial dos partidos vencedores (Figura 20) revela uma nítida polarização regional.




Figura 20. Dominância Partidária: Partido mais votado por município e espectro político (Azul: Direita, Verde: Centro, Vermelho: Esquerda).

O mapa é majoritariamente dominado pela cor azul. O eixo de Direita conquistou a vitória em **66 municípios** (aproximadamente 71% do estado). O destaque absoluto é o **Partido Liberal (PL)**, que venceu na Capital (Rio de Janeiro), em Niterói, São Gonçalo e demonstrou capilaridade total na Região dos Lagos (Cabo Frio, Búzios, Arraial do Cabo) e no Noroeste Fluminense.

O eixo de Centro, embora vitorioso em menos cidades (**15 municípios**), demonstrou força em colégios eleitorais estratégicos e populosos da Baixada Fluminense e Norte do Estado. Destacam-se as vitórias do **UNIÃO** em Belford Roxo e Campos dos Goytacazes, e do **MDB** em Duque de Caxias. Isso indica uma concentração de força política em áreas de alta densidade demográfica, em contraste com a dispersão territorial da direita.

O espectro de Esquerda obteve a vitória em **12 municípios**. A análise espacial mostra que estas vitórias funcionam como “enclaves” ou resistências pontuais, sem formar grandes manchas contíguas como os outros grupos. Destacam-se a vitória do **PT** em

conforme discutido em: Valor Econômico. *De direita ou esquerda? Veja como partidos políticos se definem no Brasil*. Disponível em: <https://valor.globo.com/politica/artigo/de-direita-ou-esquerda-veja-como-partidos-politicos-se-definem-no-brasil.ghtml>. Acesso em: 30 Nov. 2025.

Maricá (base histórica do partido) e do **PSOL** em Petrópolis (Região Serrana), além de vitórias do **PROS** e **Solidariedade** no Sul Fluminense (Resende, Itatiaia) e em Macaé.

4.5.3. Correlação com a Competitividade (HHI)

Ao cruzar a geografia partidária com o Índice Herfindahl-Hirschman (HHI), observa-se que a hegemonia visual do interior esconde uma dinâmica de baixa competitividade. O HHI é uma métrica que varia de 0 (alta fragmentação) a 1 (monopólio), calculada pelo somatório do quadrado das participações percentuais de todos os candidatos em cada município ($HHI = \sum s_i^2$).

Na análise, consideramos índices acima de 0,25 como indicativos de alta concentração (poucos candidatos com muitos votos) e índices abaixo de 0,10 como alta competitividade (muitos candidatos com muitos votos). O mapa de concentração (Figura 21) ilustra essa dicotomia espacial.




Figura 21. Mapa de Concentração Política (HHI). Áreas escuras indicam baixa competitividade; áreas claras indicam alta fragmentação.

Os dados calculados revelam os extremos dessa dinâmica. Os municípios com os maiores índices de concentração são de pequeno porte e localizados no interior, com destaque para **Aperibé (0,304)**, **São Francisco de Itabapoana (0,284)** e **Piraí (0,279)**. Nestas localidades, o índice elevado sugere que a disputa eleitoral é controlada por poucos grupos hegemônicos.

Em contraste absoluto, os grandes centros urbanos apresentaram os menores índices do estado, caracterizando um voto pulverizado. A capital, **Rio de Janeiro**, registrou o menor índice absoluto (**0,008**), configurando um cenário de hiper-competitividade, seguida por **Niterói (0,026)** e **Nova Iguaçu (0,026)**.




Figura 22. Correlação: O aumento do eleitorado (Eixo X) reduz a concentração política (Eixo Y).

A linha de tendência negativa no gráfico de dispersão ($y = -3E - 08x + 0,1058$) corrobora estatisticamente que a competição política aumenta conforme a densidade demográfica cresce. Conclui-se, portanto, que o estado apresenta uma dicotomia espacial: um interior politicamente concentrado (Direita/PL) circundando uma metrópole fragmentada e competitiva.

5. Conclusões, limitações e trabalhos futuros

A partir de dados públicos de votos, alfabetização e segurança no estado do Rio de Janeiro, este trabalho teve como objetivo colocar em prática conceitos estudados durante as aulas teóricas da disciplina requerente, incentivando o trabalho em grupo entre os participantes. Os dados eleitorais de 2022 para Deputado Estadual no Rio de Janeiro foram devidamente adquiridos, processados, agregados espacialmente e analisados.

As análises exploratórias e espaciais foram realizadas como esperado, apresentando diferentes resultados e visualizações que informam de forma clara a presença ou ausência de relação com a informação e a posição geográfica em que o município se encontra. Dessa forma, o resultado final apresentado é um rico recurso para estudos e pesquisas eleitorais e geoespaciais.

Os principais desafios foram a correta agregação dos dados do TSE, visto inconsistência no site, a utilização de diferentes softwares para gerência dos dados devido ao hardware limitado dos participantes e a harmonização das diferentes fontes. Superando os desafios, o Banco de Dados Geográfico resultante encontra-se estruturado, limpo e pronto para a execução das análises realizadas e outras desejadas. Para trabalhos futuros consideramos a possibilidade de utilizar outras fontes de dados censitários e complementares, como Índice de Desenvolvimento Humano Municipal (IDHM)¹⁵, Produto Interno Bruto (PIB) por município¹⁶ e perfil do eleitorado¹⁷ e também a oportunidade de analisar outros

¹⁵<https://dados.gov.br/dados/conjuntos-dados/idhm-indice-de-desenvolvimento-humano>

¹⁶<https://dados.gov.br/dados/conjuntos-dados/io-produto-interno-bruto-dos-municipios>

¹⁷<https://dadosabertos.tse.jus.br/dataset/eleitorado-2022>

candidatos menos votados e outras medidas de segurança como, por exemplo, homicídios.

Referências

- [Anselin 2024] Anselin, L. (2024). *An introduction to spatial data science with GeoDa: Volume 1: Exploring spatial data*. Chapman and Hall/CRC.
- [Casanova et al. 2005] Casanova, M., Câmara, G., Davis Jr, C., Vinhas, L., and Queiroz, G. (2005). *Bancos de dados geográficos*. Editora MundoGEO.
- [Davis Jr 2025] Davis Jr, C. (2025). Intro to geospatial data science. Slides de Aula da Disciplina de Bancos de Dados Geográficos e Ciência de Dados Geoespaciais. Disponível via Plataforma Moodle.
- [Econômico 2025] Econômico, V. (2025). De direita ou esquerda? veja como partidos políticos se definem no brasil. Acesso em: 30 nov. 2025.
- [Moreira and Fernandes 2018] Moreira, G. R. and Fernandes, L. R. R. d. M. V. (2018). A padronização dos nomes geográficos das indicações geográficas brasileiras: uma breve discussão. *Revista Brasileira de Cartografia*, 70(2):665–695.
- [Tobler 1970] Tobler, W. R. (1970). A computer movie simulating urban growth in the detroit region. *Economic Geography*, 46:234–240.